

*FONDAMENTI DI SCIENZA DEI DATI*  
*APPUNTI A CURA DI: RICCARDO LO IACONO*

---

*Università degli studi di Palermo*  
*a.a. 2022-2023*

---

# Indice.

<b>1</b>	<b>Introduzione: pipeline di data processing</b>	<b>1</b>
1.1	Data Integration . . . . .	1
1.2	Data integration . . . . .	1
1.3	Data reduction . . . . .	2
1.4	Tipologie di dati . . . . .	2
<b>2</b>	<b>Stimatori</b>	<b>2</b>
2.1	Mean square error . . . . .	2
<b>3</b>	<b>Tipologie di apprendimento</b>	<b>3</b>
3.1	Apprendimento non-supervisionato . . . . .	3
3.2	Apprendimento supervisionato . . . . .	3

## – 1 – Introduzione: pipeline di data processing.

Ogni progetto di scienza dei dati segue una pipeline ben definita. Questa parte dall'ottenimento dei dati, dati che possono essere acquisiti da sorgenti diverse: sensori, file di log, ecc. Indipendentemente dall'origine, ai dati sono legati due problematiche, quali

- gestione dei dati strutturati;
- gestione del volume dei dati.

Assunto di aver gestito queste problematiche, si può procedere alle fasi di data-cleaning e di estrazione delle feature. Qui con *data-cleaning* si fa riferimento ad un'insieme di tecniche atte a migliorare la qualità dei dati; in tale fase

- si gestiscono i valori nulli: questi se non gestiti porterebbero a un cattivo addestramento del modello;
- si eliminano eventuali duplicati: ciò è atto a prevenire un bias nel modello;
- si ricercano e rimuovono eventuali outliers: è ovvio che se non si procedesse a gestirli questi influenzerebbero negativamente il modello;
- si standardizzano i dati: se si utilizzano dati provenienti da fonti diverse, è necessario che questi abbiano una stessa struttura.

Successivamente si può procedere alla fase di *feature-extraction*: ossia la fase in cui si selezionano quelle caratteristiche valorizzabili dei dati, che possono essere utilizzate per addestrare il modello, ed eventualmente combinate per definire concetti più generali.

### – 1.1 – Data Integration.

Ulteriore fase della pipeline di analisi dei dati è quella di integrazione dei dati. Come anticipato, quando si addestra un modello è possibile utilizzare dati provenienti da sorgenti diverse; ciò implica verosimilmente che i dati presenteranno una struttura diversa, rendendo complicato l'addestramento del modello stesso.

Per risolvere tale problematica, nella fase di integrazione ci si occupa di uniformare la struttura dei dati, applicando eventuali trasformazioni, e di gestire eventuali inconsistenze. Con quest'ultime s'identificano dati che, sebbene associati ad uno stesso fenomeno, presentano valori tra loro discordi.

### – 1.2 – Data integration.

Nella precedente sezione si è fatto a delle trasformazioni applicabili ai dati. Queste, atte a migliorare la qualità delle informazioni, si distinguono in

- *smoothing*: si tratta di una tecnica che applica un'ulteriore pulizia ai dati, così da rimuovere ulteriore rumore;
- *aggregazione*: i dati sono combinati tra loro così da permettere la descrizione di concetti più generali;
- *normalizzazione*: si riduce il range di valori assunti.

Per quanto riguarda la normalizzazione: esisto varie soluzioni, tra le più utilizzate: la *scalatura decimale*, con la quale si riduce il range tra (0, 1); e la *z-core*, con la quale si sottrae ai dati la media degli stessi, e li si divide per la rispettiva deviazione standard.

### – 1.3 – Data reduction.

Poiché generalmente quando si opera con i dati si ha a che fare con quantità dell'ordine dei TB, sebbene ciò possa sembrare un lato positivo, in quanto il modello avrebbe più dati da cui apprendere; ciò risulta eccessivamente lento. Per questa e altre ragioni nella maggior parte dei casi si preferisce ridurre la mole dei dati (*Sezione ??*).

### – 1.4 – Tipologie di dati.

I dati porterebbero essere suddivisi per diversi aspetti, è però di interesse la distinzione tra dati *interdipendenti* e *non-interdipendenti*. Sostanzialmente la differenza è la seguente: nel caso di dati interdipendenti, questi hanno una qualche relazione ( **eg**: *peso-altezza* ); segue che informazioni in uno o più dati, dipendono o influenzano altri dati. Per i dati non-interdipendenti non si hanno tali relazioni.

**Osservazione.** È giusto puntualizzare che il concetto di interdipendenza è fortemente legato al problema in esame.

## – 2 – Stimatori.

**Definizione:** uno *stimatore* (dal punto di vista statistico), è una funzione dei dati di cui si è in possesso, che fornisce la migliore approssimazione di una quantità/proprietà a cui si è interessati.

Assunto che  $\Theta_n$  sia uno stimatore,  $\Theta$  il valore vero, si distinguono due casi

- $\Theta_n$  è polarizzato, cioè

$$\mathbb{E}(\Theta_n) - \Theta \neq 0$$

Da cui si deduce che lo stimatore commette un certo errore nell'approssimazione.

- $\Theta_n$  non è polarizzato, da cui

$$\mathbb{E}(\Theta_n) - \Theta = 0$$

Si può inoltre dire che  $\Theta_n$  è asintoticamente non polarizzato se

$$\lim_{n \rightarrow \infty} \mathbb{E}(\Theta_n) = \Theta$$

o equivalentemente

$$\lim_{n \rightarrow \infty} \mathbb{E}(\Theta_n) - \Theta = 0$$

In fine, supposto  $T_n$  uno stimatore,  $\tau$  il valore da stimare, si ha che

$$T_n \text{ è } \begin{cases} \text{corretto} & \iff \mathbb{E}(T_n) = \tau \\ \text{coerente} & \iff \lim_{n \rightarrow \infty} \text{Var}(T_n) = 0 \end{cases}$$

### – 2.1 – Mean square error.

Dato uno stimatore, sia questi  $\Theta_n$ , è necessario misurare la “bontà” dello stesso, e, in generale, per farlo si utilizza il *mean square error* (*MSE*). Questi, definito come

$$\begin{aligned} MSE &= \mathbb{E}[(\Theta_n - \Theta)^2] \\ &= \text{Bias}(\Theta_n)^2 + \text{Var}(\Theta_n) \end{aligned}$$

ove  $\text{Bias}(\Theta_n)^2 = \mathbb{E}(\Theta_n)^2 + \Theta^2 - 2\mathbb{E}(\Theta_n)\Theta$ .

## – 3 – Tipologie di apprendimento.

Quando si deve addestrare un modello di machine learning, ciò può essere effettuato secondo due “logiche”, quali:

- *apprendimento supervisionato*: al modello sono forniti dati di addestramento in cui compaiono delle etichette<sup>1</sup>;
- *apprendimento non-supervisionato*: i dati di addestramento sono, per la maggior parte di etichette.

Indipendentemente dal modello di addestramento scelto si deve fare attenzione a due problemi: *over-fitting* e *under-fitting*. Quest’ultimi fanno riferimento, rispettivamente, al caso in cui il modello, apprendendo troppo dai dati di addestramento, non è capace di generalizzare; e al caso in cui, viceversa, non avendo appreso a sufficienza, il modello non ha le capacità minime a generalizzare.

### – 3.1 – Apprendimento non-supervisionato.

Si tratta di una tipologia di addestramento alla cui base vi è l’intensione di ricercare delle similarità tra i dati. Di questi, sebbene ne esistano altri si considereranno:

- la *riduzione della dimensionalità* con la quale si tenta di ridurre il numero di osservazioni, ad uno molto minore, cercando di mantenere lo stesso livello di qualità descrittiva;
- *clustering* con la quale i dati sono raggruppati tra loro sulla base di similarità.

**Osservazione.** Nello specifico nel caso del clustering, sarà analizzato nel dettaglio il *k-mean clustering*.

### – 3.2 – Apprendimento supervisionato.

Tipologia di addestramento in cui, sulla base dei dati di addestramento, si cerca di determinare la “classe” classe di appartenenza di nuovi dati. In tale “categoria” rientrano algoritmi come

- la *regressione* con cui ai dati di input si assegna un valore numerico;
- la *classificazione* grazie al quale i dati sono divisi sulla base della classe di appartenenza stimata.

**Osservazione.** Tutto il processo di generalizzazione è di tipo statistico è basato sulla *teoria di apprendimento statistico*<sup>2</sup>.

Poiché la scelta della classe è determinata dalle conoscenze apprese, è opportuno che i seguenti errori risultino minimizzati.

- *Training error*, errore relativo ai dati di addestramento;
- *test o generalization error*, errore con cui si stima quanto correttamente il modello sia in grado di generalizzare. Nel particolare, fornendo al modello dati mai visti precedentemente, si verifica se questi sono correttamente categorizzati.

---

<sup>1</sup>Si pensi a queste come a dei campi che definiscono la classe di appartenenza del singolo record.

<sup>2</sup>Si tratta di una teoria secondo la quale tutti i dati possono essere visti come appartenenti ad una qualche distribuzione ignota, da cui si può assumere anche la loro indipendenza. Sulla base di tale ipotesi si può allora assumere che il valore atteso dei dati di addestramento e quello dei dati di test, coincidano.